Estimación del Índice de Calidad del Aire (AQI) mediante aprendizaje automático: comparación de modelos de regresión

Valentina Hoyos, Naneth Martelo, y Juan Velásquez

Dpto. de Ingeniería de Sistemas, Universidad de Antioquia
Curso Modelos y Simulación II

Resumen

Las actividades propuestas para el desarrollo del proyecto buscan que cada uno de los grupos de estudiantes aborden todo el análisis, el diseño y la simulación de un sistema de predicción basado en técnicas de aprendizaje de máquina; describiendo el problema, evaluando sus similitudes con otros proyectos y soluciones reportados en la literatura especializada, especificando cada una de las etapas del desarrollo del trabajo, los modelos usados con sus respectivas restricciones, el ajuste de hiperparámetros, la metodología de validación, los resultados de las simulaciones y las conclusiones obtenidas.

Índice

1. Introducción 1
2. Descripción del problema 1
3. Estado del arte 1
~~4. Entrenamiento y Evaluación de los Modelos 2~~
~~4.1. Configuración experimental 2~~
~~4.2. Resultados del entrenamiento de Modelos 2~~
~~5. Reducción de dimensión 2~~
~~5.1. Análisis individual de variables 2~~
~~5.2. Extracción de características lineal 2~~
~~5.3. Extracción de características no lineal 3~~
~~6. Evaluación 3~~

1. Introducción

Cada equipo de trabajo debe seleccionar un problema que pueda abordarse a partir de las técnicas y aproximaciones vistas en el curso de Modelos y Simulación II. Los problemas abordados pueden ser propuestos por el grupo de estudiantes, o seleccionados a partir del listado que será compartido por el profesor del curso. Sólo se permite que un proyecto/dataset sea desarrollado por un equipo de trabajo. El listado de proyectos sugeridos puede ser consultado en el siguiente enlace.

Cada equipo de trabajo debe crear un repositorio de GitHub en el que se alojen un reporte del proyecto (en formato pdf) y, al menos, un notebook en el que se puedan reproducir los resultados incluidos en el reporte. El readme del repositorio debe proporcionar instrucciones claras sobre cómo interactuar correctamente con él. Para el reporte se debe usar la plantilla IEEE para los artículos publicados en Transactions. Se recomienda usar un editor de texto LaTeX, en particular Overleaf. Tanto el reporte como el/los notebooks deben incluir las secciones descritas a continuación.

2. Descripción del problema

La contaminación atmosférica constituye un problema ambiental y de salud pública a nivel mundial. En ciudades como Dhaka, capital de Bangladesh, factores asociados con el tráfico, las actividades industriales y las condiciones meteorológicas pueden relacionarse con las variaciones de la calidad del aire. En este contexto, el índice de calidad del aire (*Air Quality Index*, AQI) permite representar los niveles de contaminación mediante un indicador numérico que facilita su interpretación.



Figura 1. Interpretación de los posibles valores del AQI.

El *Machine Learning* (ML) ofrece herramientas para analizar las relaciones entre las características ambientales y el valor del AQI. Por ello, este proyecto propone abordar el problema mediante aprendizaje supervisado de regresión, con el propósito de estimar el índice a partir de las variables disponibles. Se compararán tres modelos: regresión lineal, como referencia por su simplicidad e interpretabilidad; árbol de decisión para regresión (*Decision Tree Regressor*), por su capacidad para representar relaciones no lineales; y bosque aleatorio para regresión (*Random Forest Regressor*), que combina las predicciones de múltiples árboles.

Los modelos se entrenarán y evaluarán utilizando las mismas particiones de datos y características de entrada, para garantizar una comparación consistente y reproducible. El desempeño se medirá mediante el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error absoluto mediano (MedAE). Finalmente, se compararán los resultados para identificar el modelo con mejor desempeño y analizar sus limitaciones y capacidad de generalización. El alcance se limita a estimar el AQI a partir de los registros disponibles, sin realizar predicciones futuras de la contaminación atmosférica.

Para el desarrollo del proyecto se utilizará el archivo "dhaka_air_quality_no_pollutants.csv", obtenido del conjunto de datos disponible en Kaggle. La exploración inicial identificó 10.000 registros y 13 variables relacionadas con características ambientales, geográficas y del entorno urbano.

Las variables numéricas son "aqi", que representa el índice de calidad del aire; "temperature_c", correspondiente a la temperatura en grados Celsius; "humidity_pct", que indica la humedad relativa en porcentaje; "wind_speed_kmh", que expresa la velocidad del viento en kilómetros por hora; "rainfall_mm", que registra la precipitación en milímetros; "pressure_hpa", que representa la presión atmosférica en hectopascales; y "visibility_km", que indica la distancia de visibilidad en kilómetros.

Las variables categóricas son "area", que identifica el área geográfica; "station_type", que indica el tipo de estación de monitoreo; "aqi_category", que representa la categoría de calidad del aire; "wind_direction", que registra la dirección del viento mediante categorías direccionales; "traffic_level", que describe la intensidad del tráfico; y "construction_nearby", que indica la presencia o ausencia de construcciones cercanas.

En total, se cuenta con siete variables numéricas y seis categóricas. Las variables numéricas están almacenadas mediante tipos enteros o de punto flotante, mientras que las categóricas se encuentran representadas mediante cadenas de texto. Para incorporarlas a los modelos, debido a la naturaleza nominal de las mismas, se contempla el uso de *One-Hot Encoding*, que transforma las categorías en variables binarias sin introducir un orden entre ellas.

La inspección inicial no identificó valores faltantes ni registros duplicados, por lo que no se contempla realizar imputación de datos.

Se seleccionó "aqi" como variable objetivo (*target*), dado que el propósito del proyecto es estimar el valor numérico del índice de calidad del aire. La variable "aqi_category" se excluirá del entrenamiento, debido a que representa una clasificación derivada o asociada al AQI y podría introducir fuga de información (*data leakage*) en el modelo. Su exclusión busca evitar que los modelos utilicen información que revele indirectamente el valor de la variable objetivo.

La relevancia de este proyecto radica en que permite evaluar el potencial del aprendizaje automático para estimar la calidad del aire a partir de variables ambientales y urbanas, identificando los modelos de regresión con mejor desempeño como apoyo al análisis de la contaminación atmosférica.

3. Estado del arte

A continuación, se describen cuatro artículos científicos que abordan la predicción de la calidad del aire (AQI) mediante enfoques de regresión:

[1] Research on Air Quality Prediction Based on Machine Learning (IEEE). *Problema:* la contaminación atmosférica y el clima de neblina afectan la salud pública y la movilidad urbana, por lo que se requiere anticipar eficientemente los niveles de contaminación; el objetivo es pronosticar con precisión el AQI. *Método:* aprendizaje supervisado (regresión) mediante un pipeline completo, desde la recolección de datos hasta la comparación de algoritmos, en Python con Scikit-learn. Modelos: regresión lineal, árboles de decisión, Random Forest (RFR) y Gradient Boosting (GBR). *Validación:* partición 80 % entrenamiento y 20 % prueba; métricas RMSE, MAE y R^2. *Resultados:* los ensambles (RFR y GBR) superaron a los modelos tradicionales al capturar relaciones no lineales complejas. *Limitaciones:* sobreajuste de los modelos basados en árboles si los hiperparámetros no se ajustan bien y dependencia de la calidad y frecuencia de los datos históricos.

[2] Machine Learning-based Air Pollution Prediction Model (IEEE Xplore). *Problema:* el desarrollo industrial y urbano incrementa la contaminación y degrada la calidad del aire; se busca predecir las concentraciones de contaminantes y el comportamiento del AQI. *Método:* aprendizaje supervisado (regresión) con limpieza de registros históricos, preprocesamiento (codificación numérica estándar y normalización de variables de contaminantes y meteorología) y comparación de regresión lineal, Lasso, árboles de decisión y Random Forest, en Python con Scikit-learn. *Validación:* división en entrenamiento y prueba; métricas MAE, MSE, RMSE y R^2. *Resultados:* Random Forest obtuvo el mejor desempeño global y los menores errores frente a los modelos tradicionales. *Limitaciones:* sobreajuste de los modelos basados en árboles y necesidad de bases de datos limpias y sin valores faltantes para evitar sesgos.

[3] Machine learning-based prediction of air quality index and air quality grade: a comparative analysis. *Problema:* predicción a futuro del AQI como regresión multivariada con datos históricos de contaminantes. *Método:* aprendizaje supervisado con Random Forest, Gradient Boosting y Lasso para la regresión; MLP, árboles de decisión, KNN y SVM en tareas de clasificación secundarias; todos combinados mediante un ensamble tipo Stacking. *Validación:* partición 80 % entrenamiento y 20 % prueba independiente; métricas R^2, MAE y RMSE. *Resultados:* entre los modelos individuales, Random Forest fue el más preciso, pero el Stacking Regressor logró el mejor rendimiento global ($R^2 = 0.986$) y el menor error en prueba.

[4] Real-Time IoT-Based Toxic Gas Monitoring and Comparative Analysis of Machine Learning Techniques for Air Quality Index Prediction in Dhaka. *Problema:* monitoreo de gases tóxicos en tiempo real con sensores IoT y predicción del AQI en Dhaka. *Método:* aprendizaje supervisado (regresión) sobre datos históricos y mediciones de sensores, con árboles de decisión (DT), KNN, regresión

lineal/logística, análisis discriminante y SVM. *Métricas:* R^2, MSE y RMSE. *Resultados:* DT presentó el mejor desempeño ($R^2 = 0.9999$, MSE = 0.4410) y SVM el peor.

En conjunto, los cuatro trabajos coinciden en el paradigma supervisado de regresión, en el uso de particiones entrenamiento/prueba y en el mejor desempeño de los modelos basados en árboles y ensambles.

4. Entrenamiento y Evaluación de los Modelos

En esta sección se debe describir el diseño experimental y los resultados obtenidos en las simulaciones.

4.1. Configuración experimental

1. Describa la metodología de validación seleccionada para entrenar y evaluar los modelos de ML. En caso de requerir etapas adicionales, como la utilización de técnicas de submuestreo o sobremuestreo, la forma en la que fueron usadas debe estar descrita en este apartado.
2. Incluya una tabla en la que especifique el conjunto de hiperparámetros analizados durante el proceso de evaluación de cada modelo, junto con la descripción de la malla de valores utilizada para cada uno. Cada proyecto debe comparar al menos 5 modelos de aprendizaje, entre los que se deben incluir:
   - Un modelo paramétrico basado en funciones discriminantes gaussianas o en regresión (lineal o logística según se requiera).
   - Un modelo no paramétrico.
   - Un modelo basado en el ensamble de árboles de decisión.
   - Una red neuronal artificial.
   - Una máquina de vectores de soporte.
3. Describa las métricas de desempeño que se utilizarán para evaluar el sistema y justifique su uso.

4.2. Resultados del entrenamiento de Modelos

4. Presente los resultados de la experimentación para cada uno de los modelos evaluados, en los que se evidencie el efecto de los hiperparámetros en el desempeño del modelo. Haga uso de tablas y gráficas que ayuden al lector a comprender con claridad los resultados. TODAS las figuras y tablas deben ser introducidas en el texto del informe y contener un caption que las describa. Todas las figuras deben incluir los nombres de los ejes para que el lector comprenda la información que se le presenta. Las medidas de desempeño deben incluir los intervalos de confianza correspondientes estimados durante la fase de validación. Recuerde incluir los resultados de entrenamiento, validación y test.

5. Reducción de dimensión

En esta fase del proyecto, se deben evaluar diferentes técnicas de reducción de dimensionalidad y determinar si es posible reducir la complejidad del modelo final.

5.1. Análisis individual de variables

5. Realice un análisis individual de cada una de las características, a partir de medidas de correlación y/o de índice de discriminación que reflejen la capacidad discriminativa de las variables (según corresponda). Identifique, de acuerdo con este análisis, si existen y cuáles son las características candidatas a ser eliminadas.

5.2. Extracción de características lineal

6. Use el método PCA para encontrar un conjunto de componentes principales con un número de componentes inferior al de variables originales y evalúe nuevamente los 2 mejores modelos de predicción encontrados en la sección 4. Cada grupo debe decidir el criterio para seleccionar el número de componentes principales y justificar su decisión. Incluya una tabla con los resultados, indicando el porcentaje de reducción alcanzado y las demás medidas de desempeño.

5.3. Extracción de características no lineal

7. Use el método UMAP para encontrar un conjunto de componentes con un tamaño inferior al número de variables original y evalúe nuevamente los 2 mejores modelos de predicción encontrados en la sección 4. Cada grupo debe decidir el criterio para seleccionar el número de componentes y justificar su decisión. Incluya una tabla con los resultados, indicando el porcentaje de reducción alcanzado y las demás medidas de desempeño.
8. Incluya una sección de discusión y conclusiones que evalúe de forma completa la solución desarrollada, y compare sus resultados con los descritos en la sección 3.

Recuerde, cuando se cambia el espacio de características se debe realizar un nuevo ajuste de hiperparámetros. Los encontrados en la fase anterior no tienen por qué ser óptimos en el nuevo espacio de características.

6. Evaluación

Para la evaluación final del proyecto se tendrán en cuenta los siguientes criterios:

- Alcance de los objetivos de las secciones anteriores.
- No superar las 10 páginas en el reporte.
- Orden y claridad del repositorio de GitHub para reproducir los resultados.
- Sustentación: cada grupo debe preparar un video de 10 minutos que presente un resumen del proyecto. El video se proyectará durante una sesión de clase y los estudiantes deberán responder a las preguntas del público. La capacidad de cada integrante del grupo de responder a las preguntas será evaluada de manera individual.

Nota: Las secciones 2 y 3 serán evaluadas en la primera entrega de avance del proyecto.

Referencias

[1] C. Li, Y. Li, and Y. Bao, “Research on Air Quality Prediction Based on Machine Learning,” in Proc. 2021 2nd Int. Conf. Intelligent Computing and Human-Computer Interaction (ICHCI), Shenyang,

China, 2021, pp. 77–81, doi: 10.1109/ICHCI54629.2021.00022.
[2] M. Mihirani, L. Yasakethu, and S. Balasooriya, “Machine Learning-based Air Pollution Prediction Model,” in Proc. 2023 IEEE IAS Global Conf. Emerging Technologies (GlobConET), London, U.K., 2023, pp. 1–6, doi: 10.1109/GlobConET56651.2023.10150203.
[3] S. A. Aram et al., “Machine learning-based prediction of air quality index and air quality grade: a comparative analysis,” Int. J. Environ. Sci. Technol., vol. 21, pp. 1345–1360, 2024, doi: 10.1007/s13762-023-05016-2.
[4] M. Sakib, T. Sarkar, S. Das, M. Jannat, S. Akter, and M. Shahjalal, “Real-Time IoT-Based Toxic Gas Monitoring and Comparative Analysis of Machine Learning Techniques for Air Quality Index Prediction in Dhaka,” in Proc. 2024 Int. Conf. Innovations in Science, Engineering and Technology (ICISET), Chittagong, Bangladesh, 2024, pp. 1–6, doi: 10.1109/ICISET62123.2024.10939534.